

UNIVERSIDADE FEDERAL DE SERGIPE (UFS)

Programa de Pós-Graduação em Ciência da Computação

Disciplina: Tópicos Especiais em Engenharia de Software e SI I

Professor Dr. GLAUCO DE FIGUEIREDO CARNEIRO

Avaliação de Impacto de RAG e Resolução Temporal

Domínio Médico (Datasets K-QA e USMLE)

Equipe 2

GILSON INÁCIO DA SILVA Matrícula: 202611005730

Vídeo defesa técnica do Pipeline RAG e LLM as a Judge no Domínio Médico:

<https://youtu.be/he2FYtgU9A>

Repositório Oficial GitHub:

github.com/gis45ufs/Top-Avanc-EngSoft-SI-I-Med-RAG-Judge-Atividade3

Junho de 2026

Aracaju - SE

1 Declaração Explícita de Contribuições

Devido a divergências insolúveis na consistência dos dados do grupo (que resultaram na perda da base de verdade nos arquivos estáticos), as atividades desenvolvidas neste documento refletem a submissão de um *Fork* de Contingência. O *pipeline* solicitado no barema foi executado integralmente por:

- **Gilson Inácio da Silva:** Responsável único pela idealização, engenharia e execução de todas as etapas do projeto nesta ramificação, englobando:
 - **Engenharia de Dados e Infraestrutura:** Estruturação e migração de todo o ecossistema para banco de dados relacional PostgreSQL (`backup_atividade_3.sql`), blindando a integridade dos metadados e contornando a falha estrutural de gabaritos pendentes. Execução da inferência massiva local (processamento superior a 10 horas em modelos candidatos como Mistral-7b).
 - **Curadoria Fática e Motor RAG:** Seleção ativa da literatura de estado da arte (Diretrizes AHA 2024 e Relatórios FDA 2025) para resolução da cegueira temporal. Configuração do banco vetorial ChromaDB e desenvolvimento do script de indexação semântica com controle de sobreposição de *chunks* (`motor_rag.py`).
 - **Meta-Avaliação (LLM-as-a-Judge):** Desenvolvimento do orquestrador de avaliação (`pipeline_rag.py`) e formulação das rubricas clínicas isoladas (`prompts_de_sistema.md`) para garantir o registro do raciocínio diagnóstico via *Chain-of-Thought*.
 - **Análise Estatística e Visualização:** Fundamentação matemática via `calcular_evolucao_rag.py` comprovando o ganho de acurácia (+42.3%) e calculando o coeficiente de correlação de Spearman ($\rho = 0.1377$). Desenvolvimento e *deploy* do *Dashboard* analítico interativo na plataforma Vercel.
 - **Documentação e Versionamento:** Gerenciamento exclusivo do repositório Git, formatação da documentação e roteirização/gravação da defesa técnica exigida pelo barema.

2 Justificativa Técnica: Solucionando a Cegueira Temporal

A avaliação conduzida nas Atividades 1 e 2 demonstrou o grande limite dos modelos fechados ou treinados historicamente até o ano de 2023. Ao analisar as questões médicas *K-QA* e *USMLE*, notou-se uma altíssima prevalência de alucinações fáticas (Notas 1 e 2) sempre que o modelo precisava discorrer sobre fármacos recém-aprovados ou procedimentos atualizados.

Para estancar o chamado *knowledge cutoff* (Cegueira Temporal), aplicamos o paradigma de Geração Aumentada por Recuperação (RAG). Nossa equipe filtrou cirurgicamente os seguintes textos para injeção semântica:

1. Relatório da FDA de Janeiro/2025 focado na aprovação de novas drogas.
2. Diretriz AHA (2024) sobre o controle da Cardiomiopatia.
3. Diretriz AHA (2024) sobre Manejo de Risco Perioperatório.

Essa seleção garantiu que a IA avaliadora focasse em um contexto real, atualizado, anulando a margem de erro pregressa sem transformar o RAG em um "injetor de textos desconexos".

3 Arquitetura Técnica (Pipeline RAG e Banco Relacional)

A arquitetura do projeto espelha uma solução robusta e auditável, baseada nas seguintes fatias de código:

3.1 Processamento Vetorial e Recuperação

O script `motor_rag.py` fragmenta os arquivos PDF médicos via LangChain, persistindo os *embeddings* localmente usando a coleção ChromaDB. Na fase do `pipeline_rag.py`, o sistema submete o contexto das questões à Mistral e recupera (via similaridade de cosseno) os trechos documentais específicos, guiando a LLM em sua resposta.

3.2 Evolução Relacional no PostgreSQL

De acordo com os requisitos de auditoria de dados do Passo 4 da Atividade, a execução manteve as avaliações passadas intactas. As novas tabelas inseridas lado a lado compõem o *backup_atividade_3.sql*. A extração da evolução deu-se pela seguinte consulta relacional:

```
SELECT
    r_antiga.id_pergunta,
    a_antiga.nota_atribuida AS nota_sem_rag,
    a_nova.nota_atribuida AS nota_com_rag
FROM respostas_atividade_1 r_antiga
JOIN avaliacoes_juiz a_antiga
    ON r_antiga.id_resposta = a_antiga.id_resposta_ativa1
JOIN respostas_rag r_nova
    ON r_antiga.id_pergunta = r_nova.id_pergunta
JOIN avaliacoes_juiz_rag a_nova
    ON r_nova.id_resposta_rag = a_nova.id_resposta_rag;
```

4 Análise Estatística e Avaliação de Erros

A validação final cruzou exatos **16.596 pares únicos** no PostgreSQL, confrontando todas as respostas dos antigos modelos da equipe com a resposta única balizada pelo novo RAG.

Métrica	Valor Observado
Total de Pares Avaliados	16.596
Média Original (Sem RAG)	2.43
Nova Média (Com RAG)	3.46
Crescimento Absoluto	+ 42,2%
Correlação de Spearman (ρ)	0.1377
Taxa de Ruído Injetado	17,15% (2.846 casos)

Tabela 1: Quadro Resumo da Evolução LLM-as-a-Judge

4.1 Interpretação da Correlação de Spearman ($\rho = 0.1377$)

Embora uma correlação forte seja tradicionalmente buscada em avaliações de conformidade, neste experimento a **baixa correlação positiva** ($\rho = 0.1377$) prova rigorosamente que a arquitetura

RAG atingiu seu objetivo. Uma alta correlação evidenciaria que o modelo atual com RAG continuaria atribuindo notas 1 onde o modelo base também tirou nota 1. A ruptura estatística aponta que o conhecimento injetado converteu as falhas históricas em respostas de Excelência Médica (Nota 5), anulando a tendência crônica de erro da rede neural.

4.2 A Meta-Avaliação e o Controle de Ruído

Validando a eficácia e a justiça da instrução analítica (Prompt de *Chain-of-Thought*), o juiz documentou 17,15% de decréscimos da nota (*Ruído*). Esta métrica confirma que o RAG, embora poderoso para corrigir a "cegueira fática", ocasionalmente compromete respostas quando lida com consultas puramente estatísticas ou probabilísticas, onde a literatura não-correlata interfere na capacidade inferencial crua do LLM.

5 Conclusão

Este trabalho demonstra que a Engenharia de Dados aliada a técnica RAG é a solução definitiva e viável para o desafio do limite temporal das IA Generativas no setor Médico, comprovando-se com métricas fáticas, escalabilidade de bancos relacionais e *dashboards* consistentes.